

CRISP-DM

1. Business Understanding

這一步主要是了解問題的目標，並定義分析的業務需求：

業務目標：預測學生的 Exam_Score (考試成績) 會受到哪些因素的影響。這些因素包括學生的學習時間、出席率、父母參與度、資源可達性等。

分析目標：使用多元線性回歸模型來預測 Exam_Score，並且檢視各個特徵對 Exam_Score 的影響程度。

2. Data Understanding

首先，我們需要了解資料的結構，並載入資料集進行基本的檢查。資料集的特徵有 10 個以上，並且需要進行數值化處理以適應回歸分析。

資料集來源：[Kaggle Student Performance Factors Dataset](#)

3. Data Preparation

這一步是對資料進行清理和前處理，將資料整理為適合建模的格式。

- 處理缺失值。
- 進行類別資料的數值化 (例如，將 Low, Medium, High 轉換為數值型別)。
- 將資料分為訓練集和測試集。

4. Modeling

使用多元線性回歸 (Multiple Linear Regression) 來建立預測模型，並且進行特徵選擇和模型評估。

5. Evaluation

評估模型的效能，並檢視模型的預測結果。主要使用的指標為：

- 均方誤差 (MSE) : 4.40138732045496
- 決定係數 (R^2) : 0.6886194019277319

6. Deployment

由於這是一次作業分析，所以「部署」部分主要是將結果報告及程式碼交付。

NotebookLM 摘要

這是一份根據您提供的資料來源所整理的摘要，內容涵蓋多元線性迴歸 (Multiple Linear Regression, MLR) 的理論基礎、在預測學生表現上的應用方法，以及相關研究的主要發現。

摘要：多元線性迴歸與學生表現預測

1. 多元線性迴歸 (MLR) 基礎與理論

多元線性迴歸是一種**監督式機器學習技術**，用於分析兩個或多個自變數（獨立變數）與一個依變數（響應變數或稱效標變數）之間的線性關係。迴歸分析的輸出變數必須是**數值型（連續）**的，這與分類（Classification）技術的輸出變數為類別型有所不同。

MLR 的主要假設條件 若違反這些假設，MLR 的結果可能變得不可靠：

1. **線性關係（Linear relationship）**：每個預測變數與依變數之間存在線性關係。
2. **無多重共線性（No Multicollinearity）**：預測變數之間不應高度相關。通常使用**變異數膨脹因子（VIF）**來檢測，若 VIF 值大於 5 或 10，則表示可能存在多重共線性問題。
3. **獨立性（Independence）**：觀察值必須相互獨立。可使用 Durbin-Watson 檢定來判斷殘差項是否存在自我相關。
4. **常態性（Normality）**：模型的殘差項必須是常態分配。可透過 Q-Q 圖或統計檢定（如 Shapiro-Wilk 檢定，適用於小樣本）來檢測。
5. **變異數同質性（Homoscedasticity）**：殘差在線性模型中的每個點都具有恆定的方差。殘差圖中若點位分佈均勻，則滿足此假設。
6. **樣本數量**：樣本數量應為自變數個數的 5 至 10 倍。

模型評估指標 評估迴歸模型的性能時，常用的指標包括：

- **R（判定係數）**：衡量迴歸模型中可被解釋的總變異百分比，數值越高表示模型擬合度越好。
- **調整後的 R（Adjusted R）**：經自由度調整，可避免因加入過多自變數而導致 R 膨脹的高估現象。
- **RMSE（均方根誤差）**：衡量模型預測誤差的平均幅度，數值越低表示模型越好。
- **MAE（平均絕對誤差）**：衡量觀察值與預測值之間平均絕對差異，數值越低表示模型越好。
- **F 檢定**：檢定迴歸模型的整體顯著性。

2. 學生表現預測方法論（教育數據挖掘）

將數據挖掘技術應用於教育資料庫以預測學生表現的過程稱為**教育數據挖掘**（Educational Data Mining, EDM）。

預測模型建構流程 (El Alloui et al. 的方法):

1. **分析與預處理**：使用統計分析方法對學生的屬性/變數進行分析和預處理。例如，進行探索性分析以檢查變數是否常態分佈、是否存在異常值，並測試自變數與依變數之間是否存在線性關係（如使用散佈圖）。
2. **變數選擇**：使用不同的方法選擇**最重要的變數**。
3. **模型構建與比較**：基於選定的變數構建不同的 MLR 模型，並使用 k-fold 交叉驗證技術比較它們的性能。

變數選擇方法 研究人員採用了多種方法來量化變數的重要性，包括：

- 隨機森林（Random Forest）
- 相對重要性套件（relaimpo）中的方法，例如 LMG、First、Last
- 多元自適應迴歸樣條（MARS）
- Boruta 方法

3. 影響學生表現的關鍵因素與實證發現

兩份研究（El Alloui et al. 和 Pei, C.）均使用 MLR 來預測學生表現，但側重因素和結果略有不同：

因素類別	El Alliouï et al. (預測 G3 期末成績)	Pei, C. (預測 GPA)	另一數據集分析 (預測 Exam Score)
最重要的預測方法	MARS 方法表現最佳，R-squared 最高。	使用 逐步迴歸 篩選出的改進模型，擬合度高。	-
學習習慣	每週學習時間 (studytime) 是入選的重要變數之一。	每週學習時間 有顯著正向影響。	出席率 (0.58) 的相關性強於 學習時數 (0.45) 。學習時數增加，分數傾向提高。
家庭/環境	母親教育程度 (Medu) 具有正向相關係數。	家長支持 有顯著正向影響。	家長教育程度 和 家庭收入 對中位數成績影響不大。
社會因素/課外	年齡 、 外出社交 (goout) 和 戀愛關係 (romantic) 增加，會導致期末成績下降。 額外教育支持 (schoolsup) 也是負向相關。	輔導 、 課外活動 、 體育 、 音樂 均有顯著正向影響。	輔導 對不同分數組學生的影響有限。教師品質和學校類型對考試分數影響不顯著。
負面因素		缺席次數 與 GPA 呈最強負相關。	缺席次數在相關性熱圖中未被列出，但出席率 (Attendance) 與分數呈強正相關。
非顯著因素		年齡、性別、種族、家長教育程度和志願服務對 GPA 影響微乎其微。	性別、家長教育水平、家庭收入、動機水平、家長參與和學校類型對考試成績影響不顯著。

結論性見解 有研究指出，學生的**個人學習習慣**和**參與度**（如出席率和學習時間）可能比傳統上認為影響重大的外部因素（如學校類型、輔導或教師品質）更重要。然而，某些家庭因素如**母親教育水平**和**家長支持**仍顯示出積極的預測作用。